


inferential statistics - Day 5



هذا أع sample أقدر، اهل على statistical inference


لازم تكون :

probabilistic sample →

random simple


→ probabilistic sample → each member has equal probability to be selected

والتي يكون من كل phenomena الى الـ low



→ non-probabilistic sample → inferential statistics
 ما هو ليس أع لازم تكون random من biased

→ sample $\xrightarrow{\text{نمونه}}$ experiment design



* Non-Sampling Techniques:-

① Convenience

→ obtain a sample of convenient elements
 → part of population that close to hand
 → respondents are selected bec they happen to be in the right place at the right time.

هنا أنا ياخذ اسامى sample بل فقا

② Judgement

→ selected based on opinion of an expert
 ياخذ، اى شخص اوس خبره

③ Quota

- select sample based on pre-set proportions for specific subgroup
- viewed as two-stage restricted judgement
- first consisting of developing control categories
- second, elements selected based on convenience or judgement

في الاول يختار اكم الى عايرك اجرية جيارك لى طرف

④ snowball → initial participants recruit new participants from their social network

يكلم الناس في الاول يرشحون غيرهم وهكذا

Non probability → Not representative → biased

* probability sampling كلهم random ولين انما جيارك على حسبك

pop و rep و sample و pattern

- ① symmetric
- The sample is chosen by selecting starting point and then picking every i th element
 - interval, i is determined by dividing the pop size, N by sample size n and rounding to the nearest integer

10	
20	
30	

20
20
20


← **cyclic pattern** rep لو عندي **rep** لو عندي **cyclic pattern** وليكن في بعض الكالات ممكن تكون عيب وشكوتس **rep** خالص

← لو عندي **data** عبارة عن F, M وار $M \rightarrow \text{even}$ و F و $odd \rightarrow F$ و لو اشرت اي رقم هيد طلع **Category** واحد من

② **Simple random** → عيب! لو عندي **clusters** ممكن في **cluster no data** اى **cluster** من ذلك هو اقل دفع **no** باقي الفرق ولكن بسيط وتكلفته قليله ولكن من يبيصن البيانات تكون **rep**


③ **stratified** → dividing population into homogenous subgroups called strata. Then make sure our survey includes people from subgroup

بتخفف اى اشرت من كل group



④ **proportional stratified** → the size of the sample drawn from each stratum is proportional to the relative size of that stratum in the total population

لفهم الفكرة بين الفرق هنا! أنه لو فارقته معاً بالنسبة كل قط على كل sample
نسبة إلى pop



- ⑤ **cluster** →
- ① define your population
 - ② divide your sample into groups
 - ③ randomly select clusters
 - ④ collect data from sample

يكون مفيد لو كل ال groups بالإنساني واحد ومفيد بين الفرق بينهم

sampling distribution

Confidence interval

Hypothesis testing

* Sampling distribution :-

$$N = 6$$

Sal (\$1000)

A	3
B	6
C	4
D	9
E	7
F	7

$$M = 6$$

$$S^2 = 4, \quad S = 2$$

→ point estimate → sample data وبتسبغ
الـ $\bar{x}$ والى بيطلع بيكون هو estimation على الـ pop

→ unknown parameter estimation → Known sample statistic

• Size $n = 2$


$$\text{# of different combinations} = \frac{N!}{n!(N-n)!} = \frac{6!}{2!4!} = 15$$

→ Values of $\bar{x}$ for all possible samples

Sample	Values	$\bar{x}$
AB	3,6	4.5
AC	3,4	3.5
AD	3,9	6
AE	3,7	5
AF	3,7	5
BC	6,4	5
BD	6,9	7.5
BE	6,7	6.5
BF	6,7	6.5
CD	4,9	6.5
CE	4,7	5.5
CF	4,7	5.5
DE	9,7	8
DF	9,7	8
EF	7,7	7

• $\bar{x}$ vary from 3.5 to 8

• $\bar{x}$ has distribution s. → frequency




↑
distribution of Mean
of samples

$\bar{x}$	Frequency	RF
3.5	1	1/15
4.5	1	1/15
5	3	3/15
5.5	2	2/15
6	1	1/15
6.5	3	3/15
7	1	1/15
7.5	1	1/15
8	2	2/15


• sampling distribution


→ continuous



لو أنا معايا ال graph دا أقدر
أعرف مثلاً أي احتمال لو خذت
sample ال $\bar{x}$ يكونه على range معين

→ Mean of pop = Mean of
means of all possible
samples





← لو عرفت بشكل ما ابني $\bar{x}$ لـ sample الى صحتها بغير 3 std عنه
 الـ μ يعني وقتها هتشك انه الـ sample ديه تحت الـ pop ديه لانه
 الاحتماليات انيها تظهر قليل جداً ← 0.15%
 ← بشكل عام كل ما الـ $\bar{x}$ بيعد عنه الـ pop هتكونه احتماليات اني يطبع
 قليل

variance of sampling distribution

$\bar{x}$	$x - M$	$(x - M)^2$	F	P
3.5	-2.5	6.25	1	6.25
4.5	-1.5	2.25	1	2.25
5	-1	1	3	3
5.5	-0.5	0.25	2	0.5
6	0	0	1	0
6.5	0.5	0.25	3	1.75
7	1	1	1	1
7.5	1.5	2.25	1	2.25
8	2	4	2	8
Total			24	

• Sampling variance = $\frac{24}{15} = 1.6$

• standard error $\equiv$ standard deviation of sampling distribution, so $S.E.(\bar{x}) = \sqrt{\text{Var}(\bar{x})} = \sqrt{1.6} = 1.265$


• $\text{Var}(\bar{x}) = \frac{N-n}{N-1} \times \frac{\sigma^2}{n}$

غالباً n يكون
بعده جداً عن N
فأشأنه يكون $\approx$


لذلك يمكننا أن نكتب $\text{Var}(\bar{x}) \approx \frac{\sigma^2}{n}$

العلاقة بين Var لـ Sample و Var لـ Pop: $\text{Var}(\bar{x}) = \frac{N-n}{N-1} \times \frac{\sigma^2}{n}$

وإذا قلنا إن كل ما هو n يتغير، Var sampling يقل، والعكس صحيح.



هنا الفرق بين n لأن القيم زفت متصوي
أكثر حوالين M فـ n يسبب إلى أخذ Sample
بـ n Size دا M $\bar{x}$ منها يكون بعد عن M
لـ Pop يقل جداً.




* distribution of sample mean depends on:

- $n \rightarrow$ sample size
- $\sigma \rightarrow$ std of pop
- $\mu \rightarrow$ Mean of pop


* Central Limit Theorem:-

Pop. is sample distribution of pop distribution
 distribution of sample combinations
 Normal distribution of sample size mean
 sample size ≥ 30

$N = 1,000,000$





exponential distribution




distribution of sample Mean $\rightarrow$ Normal dist

← و لنفس السبب دأ لما كنت برود عدد الـ **trials** في الـ **bernouli** كان
 بيدطالع الـ **Normal dist** لأن وقتها نخلص كافي ياخذ **sample size n**
 منه **bernouli dist** واجب الـ **Frequency** بالنسبة الـ **dist**
 ↳ **distribution of sample mean**




← في الكيفية مقدرين اعمل كذا ؟ بعض مقدرته اخذ **sample size**
 و آخذ اكثر منه **Sample** ليعدينه ارسو الـ **dist** لأن باحكلف زنا
 و هند فكره الـ **Sample** في الاصل



Population $\rightarrow 100,000,000$ μ
 Sample $\rightarrow 100,000$ $\bar{X}$
 $\downarrow$
 point estimation
 $\downarrow$
 How Certain
 90,000 100,000 110,000
 └──────────────────┘
 Confidence interval $\rightarrow$ C level


$\rightarrow$ Confidence interval $\xrightarrow{\text{narrower}}$ better
 $\rightarrow$ Confidence level $\xrightarrow{\text{high}}$ better

$$S.E = \frac{8}{\sqrt{n}}$$



$$\rightarrow P(\bar{X} \text{ within } 2 \text{ S.E}) = 95.4\%$$


$$\rightarrow P(80 \leq \bar{X} \leq 120) = 94.4\%$$



$$\rightarrow P(80 < \bar{X} < 120) = 95.4\%$$

$$\rightarrow CI = [80, 120] \rightarrow CL = 95.4\%$$

← دا معناه اینی لو ائتد sample 100 هیهطبع 95٪ منه ال $\bar{X}$ بینه 80, 120



$$CI = [\bar{X} - 2 S.E, \bar{X} + 2 S.E]$$

$$CL = 95.4\%$$


و دا معناه اینی لو وقت sam 100 هیهطبع
95٪ منه ال μ بینه ال CI

← دا معناه اینی اب $\bar{X}$ لو حرمت

درودت علیها 2 S.E ههونه

هئا کده 95.4٪ اینی ال μ فی ال

intervals



→ $CI = [\bar{x} - 3 S.E, \bar{x} + 3 S.E]$

→ $CL = 99.7\%$

← عشانہ آخذ accuracy اور اوسط یعنی اوسع ال range

For the same sample size:

accuracy $\xrightarrow{\text{high}}$ interval
 $\xrightarrow{\text{high}}$


علاقہ عکسہ بننے ال accuracy و
 ال range

← عشانہ اقدر اُرد ال accuracy

← range ما اُکبر ال


← Sample Size ال بڑود

لان دا هقتل ال $S.E$



→ $\hat{\theta} \approx S \rightarrow$ sample estimation

لو عايزه اُجيب مثلا "CI=95"



$$\text{norm. ppf} \left(0.5 - \frac{0.95}{2} \right)$$

→ $n \uparrow \rightarrow \text{margin of error} \downarrow \rightarrow \text{width} \downarrow$
 E

→ $\bar{c} \uparrow$ → " " " $\uparrow$ → " $\uparrow$

* Conditions for inference on a Mean:-

① **Random** → a random sample or randomized exp should be used to obtain the data. بى رندم

② **Normal** → The sampling distribution of $\bar{x}$ (The sample mean) needs to be approximately normal. This is true if our parent pop is normal or if our sample is large $n \geq 30$.

③ **Independent** → individual observation need to be independent. if sampling without, our sample size shouldn't be more than 10% of the pop.

underestimation

E₀

دائماً لما الـ n تكون صغيرة، الـ S يكون أقل منه الـ σ

لما الـ $sample$ يكون صغير، الـ var للداتا مش يكون بابتها، ف لو القيمة بحدده عنه بعض، لما يحسب الـ var ، يكون الفرق بينه الأرقام $\bar{x}$ والـ $\bar{x}$ أصغر دائماً منه القيمة الحقيقية، لأن الـ $\bar{x}$ مستود تاصيه الـ $sample$ لما يربح الفرق الصغير، وأجبه دائماً يكونه أقل منه الحقيقي.

لما إن الفرق دائماً يكون أصغر

ف تقسمه على $n-1$ أو dof

بحيث الـ var يكون أكبر وأقرب للـ σ^2

كما أن الفكرة إن دائماً في قيمة

حساب هذين في الـ var لأنها محسوبة

منه فيوتانيه عشائه نحافظ على المتوسط

ف مش يقسم عليها

كل ما الـ n كبير ($n > 10000$) طين الفرق اقص على $n-1$ أو n ، لأن

الفرق بينهم ضئيل مع الأرقام الأكبر، ثابتاً لأن الـ $\bar{x}$ بغير منه الـ μ في النهاية

$$CI = \bar{X} \pm Z * S.E$$

$\frac{S}{\sqrt{n}}$
مقياس هام في
المعادلة تطلق أفرد
أكبر


لذلك يكون في الـ Z يدل الـ $S.E$

dof ← $(t - distribution)$ على حسب

z -value $\rightarrow$ لو ال z معروف

t -value $\rightarrow$ لو ال t مش معروف

$\text{dof} = 1000 \rightarrow z\text{-value} = t\text{-value}$



* Hypothesis test :-

Assumption

Fact


$\rightarrow$ Nullify

assumption $\rightarrow$ fair coin $\rightarrow p=0.5$


H_0 $p=0.5$

H_1 $p \neq 0.5$ $\left[\begin{array}{l} p > 0.5 \\ p < 0.5 \end{array} \right.$

Collect data



مقريش من Sample واحدة احكر على كل ال pop لان من ال $Sampling dist$ ← ممكن نطلع في أي مكان



اب ال $prop$ اني احصل على ال $prop$ التي p -value →
 صليتي من ال Sample لو ال M اي مال H_0 نقول


• $p\text{-value} < \alpha$

↳ significance
 (0.05) level

ساعتها نغير اكل $reject$ للفرض
 واقول انها غلط

• $p\text{-value} > \alpha$

مش هقد، اكل $reject$ لا H_0
 مش بقول انها صح ولكن مقريش
 دليل انها غلط

H_0 H_1 

مقدرش اقول! نه H_0 غلط و مقدرته

اقول ازها مع

evidence → data (sample)

یا بول reject لا مس بول
accept


significant level (α) = 0.05

* example: -

H_0 $p = 0.5$

H_1 $p > 0.5 \rightarrow P(H_1) > P(H_0)$


- Collect data 1000 sample → $\bar{p} = 0.6$ ($p > 0.5$)



اقدام $\mu = p = 0.5$

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n} = \frac{p(1-p)}{n} = 2.5 \times 10^{-4} \quad \text{S.E.} = 0.0158$$

$$- P(\bar{P} > 0.6)$$




$$- Z = \frac{0.6 - 0.5}{S.E} = 6.329 \quad (Z\text{-statistic})$$

$$- p\text{-value} = 1 - \text{norm.CDF}(6.329) = 1.33 \times 10^{-10}$$


- rejection region

يعرفها قبل ما أبدأ ال test



$$- p\text{-value} < \alpha \rightarrow \text{reject } H_0$$

$$z_{critical} = \text{norm.ppf}(0.95) = 1.64$$



بعد ما حددت قيمه α
 ليحسب الـ z الي كمللي
 الذسيه دي

z-test

$\rightarrow z = z_{critical} \rightarrow \text{reject}$
 $\rightarrow z < " " \rightarrow \text{not reject}$

في المثال دا أنا استخدمت الـ $z\text{-score}$ لأن أولاً $n=1000$ كافيًا أنا
 معايا المعلومات الي نحتاجها لـ z وانا هنا كدة منه قيمت ولكن في
 احتمال ثاني لازم استخدم $t\text{-score}$