


regression analysis

 $x, y \rightarrow \text{dep. reg model}$ يعرف بيها قيمة التغير بين x و y
خط مستقيم يوصف العلاقة

$$y = ax + b$$

slope $\rightarrow$ bias (intersection with y axis)

العلاقة بين x و y لما x بصفر كان y يساوي b


كل ما يزيد معناه $a = \frac{y}{x} \rightarrow$
أنه x ليس تأثير أكبر

$a = 10$

$a = 5$

$a = 2$


single LR

لو قدرت احيي العلاقة ف هقول
predictionمن احتماله C كثيره عن b و a

$$\left[\begin{array}{c} \leftarrow a \rightarrow \\ \leftarrow b \rightarrow \end{array} \right] \begin{array}{l} \text{range} \\ (CI) \end{array}$$

$$\text{Square error} = \sum_{i=1}^n (\hat{y}_i - y_i)^2 \xrightarrow{\text{obj}} \text{minimize square error}$$

$$y = ax + b + \epsilon_i \quad \hat{y} - y = \epsilon_i$$



دا بتفعل ال **overfitting** يعني
المودل حفظ بدل ما يعمل العلاقة
الحقيقية وديه ينمذها لما
المودل راجب **accuracy**
عالية في ال **training**
وقليلة في ال **test**

الطريقة اللي بيجب بيها **a, b**
هي ال **ols method**


لما اطلع ال **regression line** لازم استخدمه في اقل **prediction**
لنفس ال **range** اللي جيت منه ال **line** عشان ممكن برا ال **range**
يحدث تغير.

* Multiple Linear regression

x_1	x_2	y
5	6	100
3	4	150

$$y = b_0 x_0 + b_1 x_1 + b_2 x_2$$

b_0 → intercept / bias



$$y = x^T b$$

$$y = \begin{bmatrix} x_0 & x_1 & x_2 \end{bmatrix} \begin{bmatrix} b_0 \\ b_1 \\ b_2 \end{bmatrix}$$

$$\hat{y} = x b$$

$$\underset{\substack{\uparrow \\ \text{vector}}}{y} = \underset{\substack{\downarrow \\ \text{matrix}}}{x} b + \underset{\substack{\uparrow \\ \text{vector}}}{\epsilon}$$

vector matrix vector
(min)

*OLS (Ordinary square error)

$$b = (x^T x)^{-1} x^T y$$

*Multiple LR:

$$\hat{y} = b_0 x_0 + b_1 x_1 + \dots + b_k x_k$$


*Multivariate:

$$\begin{array}{c|c|c|c|c} x_1 & x_2 & x_k & y_1 & y_2 \end{array}$$

more than dep var

أوقات يتم استخدام multivar
multiple LR في
هذا النوع

* Error quantification



- Coeff of determination = R^2


مقياس [R²] اهدراكم
بييه
worst ← best

- $MSE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$

- $MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|$

- $RMSE = \sqrt{MSE}$

المشكلة في الانواع اعلى مش
يكون عاظم الفرق حلو ولا
أقدر اعرف في حالتي:-
① لو يقارن 2 models
② اكون عاظم الداتا كويس



$$SSR = \sum_{i=1}^n (\hat{y}_{(i)} - \bar{y}_{(i)})^2 \quad \text{explained variance}$$

$$SS_{res} = \sum_{i=1}^n (y_{(i)} - \hat{y}_{(i)})^2 \quad \text{unexplained variance}$$

$$SST = \sum_{i=1}^n (y_{(i)} - \bar{y}_{(i)})^2 = SSR + SS_{res} \quad [0, 1]$$

$$\frac{SS_{res}}{SST} = \frac{\text{unexplained}}{\text{Total}}$$


$$R^2 = 1 - \frac{SS_{res}}{SST}$$

[0, 1]
 ↓
 worst → best

$$R^2 = \frac{SS_{reg}}{SST}$$

العلاقة بين SSR و SS_{res} عكسية
 $SSR \leftarrow \downarrow SS_{res} \leftarrow \uparrow SSR$
 لغرب من SST

دب برضو بستخدم بس الثانية اكثر



$$R^2 = 1 - \frac{SS_{res}}{SST} = -\square$$

يعرف هذا بأنه Model خطي

$$R^2 = \frac{SSR}{SST} > \square$$

$R^2 =$

$$R^2 = \frac{SSR}{SST} / 1 - \frac{SS_{res}}{SST}$$

chi-square

chi-square

$$R^2 \rightarrow \frac{\text{Chi}}{\text{Chi sig test}} \rightarrow F\text{-dist}$$

F-test

$$\text{adjusted } R^2 = 1 - \frac{(1 - R^2)(N - 1)}{N - p - 1}$$

of data $\rightarrow$ $N - p - 1$ $\rightarrow$ # of features

if features increased →
ليس الزيادة فيه من مؤثره

$$R^2 \rightarrow 0.8 \rightarrow 0.81$$

التأثير من كبيراً هم لأن الزيادة ضئيلة

$$adj R^2 = 1 - \frac{(1-R^2)(N-1)}{N-p-1}$$

↓
↓
↓
adjusted R^2 ↓

if featured increased →
والزيادة فيه فعلاً مؤثرة

$$R^2 \rightarrow 0.8 \rightarrow 0.9$$

هيفل

$$adj R^2 = 1 - \frac{(1-R^2)(N-1)}{N-p-1}$$

↓
هيفل ليس بنفس اقل منه
التي فوقه

adjusted R^2 ↑

* significance test:-

$$H_0 : R^2 = 0$$

$$H_1 : R^2 > 0$$

$$R^2 = \frac{\text{Chi-square}}{\text{Chi-square}} \rightarrow F\text{-dist}$$


$$F\text{-value} = \frac{(R^2 - 0) / K}{(1 - R^2) / (n - K - 1)}$$

$$F = \frac{R^2 - 0}{1 - R^2} \cdot \frac{n - K - 1}{K}$$

$$SST = SSR + SS_{res}$$

$$n - 1 = K + SS_{res}$$

$$SS_{res} = n - K - 1$$




كل ما R^2 تكبر كلما الـ F تكبر
كل ما توصل الـ rejection region

* significance test reg Coef :-

$$\hat{y} = \underbrace{b_0}_{\text{coef}} x_0 + \underbrace{b_1}_{\text{coef}} x_1 + \dots + \underbrace{b_k}_{\text{coef}} x_k$$


b_k contribute error $\epsilon \rightarrow$ normally distributed

t-test $\leftarrow$



$$\hat{y} = a + b x$$

$\uparrow$
0 $\bar{y}$



لو x بصفر بتفي ساعتها المودل هيكونه
 كهو $\bar{y}$ وهيكونه x ملهاش اي تأثير
 على $\bar{y}$

$$H_0: b = 0$$

$$H_1: b \neq 0$$

$$t = \frac{b_j - 0}{S.E.}$$

$$\hat{y} = b_0\alpha_0 + b_1\alpha_1 + \dots + b_k\alpha_k$$


↓ مسا.

OLS

→ t-value

لترتيب 2*


P-value




* Assumptions of simple LR:-

- ① Independence of observation
- ② Homogeneity of variance

عشوائية error فيكون في
جدها أكثر من حدة




Homoscedasticity



Heteroscedasticity

③ Normality



يعرفها عنه كطريقة اني بدرس error
ولو صح هي طبع normally dist

④ relationship between x, y is linear

Scatter plot يعرفه كارتيف ال

multiple var ← يدرس كل var مع ال y
بجمل $Corr(x, y)$

⑤ Multicollinearity

لو في علاقة بين 2 features مش هتخلي مشكلة بس مش يكون عارقه
أي feature هتأثر
بستخدم PCA ← بتبديل ال x_1, x_2 بـ z

• Coefficient of determination

→ determine how much
explained variance بالنسبة
total variance ال

• Correlation $\rightarrow$ y و x بين $\rightarrow$ هتطلع

R squared $\rightarrow R^2$

• كل ما ال p -value يقل كد ما يكون ال param أحسن لأن ال
 H_0 إنه ال $b = 0$ وكد ما يكون ال contribute ل x احسن

* How we know prob :-

① Theoretical $P(H) = 0.5$

$P(T) = 0.5$

② Experimental $\text{فرضی و experiment کے}$

$P(H) = 0.6$

$P(T) = 0.4$

③ Subjectively $P(WW3) = 90\%$

80%

20%

ہم کو یہ دینا چاہیے کہ
 او ایسا کہتا ہے کہ
 اس شخص

* Bayesian inference :-

$P(WW3) = 0.1$

$$P(WW3 | \text{اوسا اوکرتا}) = 0.5 \quad (\text{update belief based on evidence})$$

↓
data

$P(WW3) = 0.1$

$\xrightarrow{P(A)}$

$P(A) = 0.1$

$P(R|U) = 0.8$

$\xrightarrow{P(B)}$

$P(B) = 0.8$

$$P(WW3 | R|U) =$$

↓ A
↓ R

$\xrightarrow{P(A|B)}$

$P(A|B) =$

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

↓
posterior

 $\longrightarrow$ general multiplication rule

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$P(A \cap B) = P(A|B) \cdot P(B)$$

$$P(A \cap B) = P(B|A) \cdot P(A)$$

$$P(A \cap B) = P(B \cap A)$$

$$P(B \cap A) = P(B|A) \cdot P(A)$$


$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

↑
← prior
Bay's Theorem

posterior

example 1:-

العمار ناس من [0, 100]



$$P(40 < \text{ages} < 60) \approx 68\%$$

$$P(30 < \text{ages} < 70) \approx 95\%$$

$$P(1 < \text{ages} < 10) \approx 0.05$$

$$P(A|K \text{inder}) = \frac{P(B|A)P(A)}{P(B)}$$

لما علت and prob

كدا يكون مقاديرنا مع

ال pop كله $P(A)$

لذلك مقاديرنا استخدم

ال Frequency

* example 2:-

• $P(\text{Fire}) = 1\% = 0.01$

• $P(\text{Smoke}) = 10\% = 0.1$

• $P(\text{Smoke} | \text{Fire}) = 90\% = 0.9$

• $P(\text{Fire} | \text{Smoke}) = \frac{P(\text{Smoke} | \text{Fire}) P(\text{Fire})}{P(\text{Smoke})} = \frac{0.01 \times 0.9}{0.1} = 9\%$

↑
posterior

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

← prior

← عادة من بيتي وول عيني


* Law of Probability:-

كيفية marginal prob.

• $P(B) = P(B \cap A_1) + P(B \cap A_2) + P(B \cap A_3) + P(B \cap A_4)$

• $P(B) = P(B|A_1) \cdot P(A_1) + P(B|A_2) \cdot P(A_2) + P(B|A_3) \cdot P(A_3) + P(B|A_4) \cdot P(A_4)$

• $P(B) = \sum_{i=1}^n P(B|A_i) P(A_i)$




$$P(A|B) = \frac{P(B|A) \cdot P(A)}{\sum_{i=1}^n P(B|A_i) \cdot P(A_i)}$$

$$P(B|A) + P(B|A^c) = 1$$

X

Intersect $\rightarrow P(B \cap A) + P(B \cap A^c) = 1$



$$P(A|B) + P(A^c|B) = 1$$

✓

*example 1:-

100 $\xrightarrow{\text{اكيد كندهم}}$ Gona

$$P(+ve|D) = 0.8$$

80 +ve

$$P(-ve|D) = 0.2$$

20 -ve

$$P(+ve|D) + P(-ve|D) = 1$$

*sum of Conditional prob:-

$$P(A_1|B) + P(A_2|B) + P(A_3|B) + P(A_4|B) = 1$$



$$\sum_{i=1}^n P(A_i|B) = 1$$

*example 2:-

$$P(D) = 0.01\% \quad 0.0001$$

$$P(+ve|D) = 99\% \quad 0.99$$

$$P(-ve|D^c) = 99\% \quad 0.99$$

 $\Rightarrow \text{Test} \rightarrow +ve$

$$\begin{aligned}
 P(D|+ve) &= \frac{P(+ve|D) \cdot P(D)}{P(+ve|D) \cdot P(D) + P(+ve|D^c) \cdot P(D^c)} \\
 &= \frac{0.99 \times 0.0001}{0.99 \times 0.0001 + 0.1 \times 0.9999} = 0.0098 \\
 &= 0.98\%
 \end{aligned}$$

- داهناه انه كل ... هيهلو ال **test** وهيطلع **+ve** وواحد منهن ب
الى هيكون عنده المرض يعني ال **test** سرجيذا
- ودا لان **prob** وجود المرض قليله جذا، و كمان في **prob** انه هيطلع
مريض من لو ال **test** ب **+ve**

* Montey Hall: D_A, D_B, D_C M_A, M_B, M_C (1 Prob)

→ I Choose A, Montey opens B

→ A or C?

$$P(D_A) = P(D_B) = P(D_C) = \frac{1}{3}$$

$$\begin{aligned}
 P(D_C|M_B) &= \frac{P(M_B|D_C) \cdot P(D_C)}{P(M_B|D_C) \cdot P(D_C) + P(M_B|D_B) \cdot P(D_B) + P(M_B|D_A) \cdot P(D_A)} \\
 &= \frac{1 \times \frac{1}{3}}{1 \times \frac{1}{3} + 0 \times \frac{1}{3} + \frac{1}{2} \times \frac{1}{3}} = \frac{2}{3}
 \end{aligned}$$

$$P(D_A|M_B) = 1 - [P(D_B|M_B) + P(D_C|M_B)] = 1 - \frac{2}{3} = \frac{1}{3}$$

→ it's better to switch!